zCore 入门导引

张译仁

2022.3.19

提纲

- **总体介绍**
- 各模块实现

总体介绍 -- 特征

zCore: A Next Gen Rust OS

- Rust 语言编写的“混合”操作系统内核
  - 同时支持 Linux 和 Zircon 系统调用
  - 同时支持 LibOS 和 裸机 OS 形式
  - 可以完全在用户态开发、测试、运行
- 内核协程化
  - 扩展 Rust Async 机制
  - 重新思考 syscall 以及调度

总体介绍 - 项目规模

目前大约 3.8 万行左右代码量

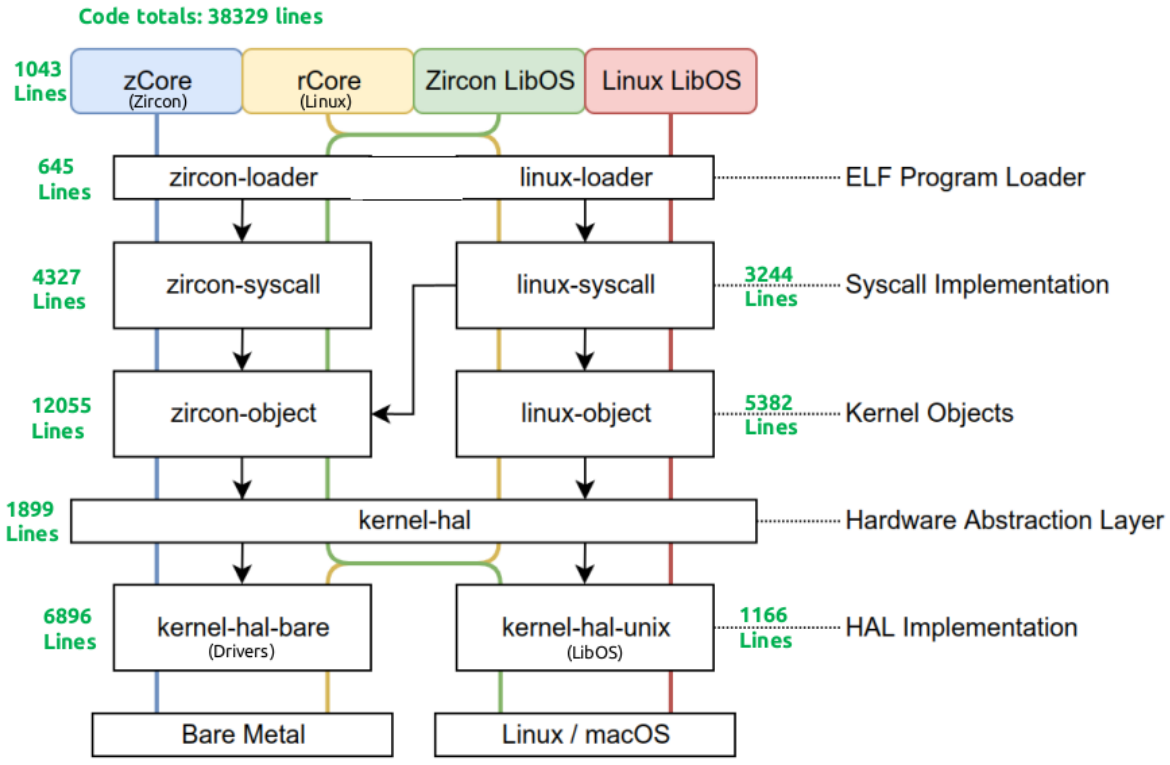

总体介绍 - 完成度

Zircon 官方系统调用测试集

Test	Status
Bti	⚠️ 7/8
ConditionalVariableTest	✅ 3/3
C11MutexTest	✅ 5/5
C11ThreadTest	✅ 6/6
ChannelInternalTest	✅ 2/2
ChannelTest	✅ 38/38
ChannelWriteEtcTest	✅ 27/27
ClockTest	✅ 2/2
ProcessDebugUtilsTest	✅ 1/1
ProcessDebugTest	❌ 0/4
ExecutableTlsTest	✅ 12/12
EventPairTest	✅ 8/8
FifoTest	✅ 9/9
FPUTest	✅ 1/1
FutexTest	✅ 14/14
HandleCloseTest	⚠️ 2/3
HandleDup	✅ 4/4
HandleInfoTest	✅ 4/4
HandleTransferTest	✅ 2/2
HandleWaitTest	✅ 2/2
InterruptTest	⚠️ 6/7
JobTest	⚠️ 8/26
MemoryMappingTest	⚠️ 5/8
ObjectChildTest	✅ 1/1
ObjectGetInfoTest	✅ 4/4
JobGetInfoTest	⚠️ 24/39
ProcessGetInfoTest	⚠️ 25/69
TaskGetInfoTest	⚠️ 11/12
ThreadGetInfoTest	⚠️ 26/41
VmarGetInfoTest	⚠️ 19/21
ObjectWaitOneTest	✅ 5/5
ObjectWaitManyTest	✅ 5/5
Pager	❌ 0/76
PortTest	⚠️ 10/18
ProcessTest	⚠️ 8/26
SchedulerProfileTest	❌ 0/14
Pthread	✅ 6/6
PThreadBarrierTest	✅ 3/3
PthreadTls	✅ 1/1
Resource	❌ 0/11
StackTest	✅ 2/2
StreamTestCase	❌ 0/11
SyncCompletionTest	✅ 11/11
SyncCondition	✅ 2/2
SyncMutex	✅ 3/3
SystemEvent	❌ 0/9
Threads	⚠️ 12/36
TicksTest	✅ 1/1
Vmar	⚠️ 4/33
VmoCloneTestCase	✅ 6/6
VmoClone2TestCase	⚠️ 32/41
VmoCloneDisjointClonesTests	✅ 2/2
VmoCloneResizeTests	⚠️ 2/4
ProgressiveCloneDiscardTests	✅ 2/2
VmoSignalTestCase	✅ 3/3
VmoSliceTestCase	⚠️ 15/15
VmoZeroTestCase	✅ 12/12
VmoTestCase	⚠️ 13/27

总体介绍 - 完成度

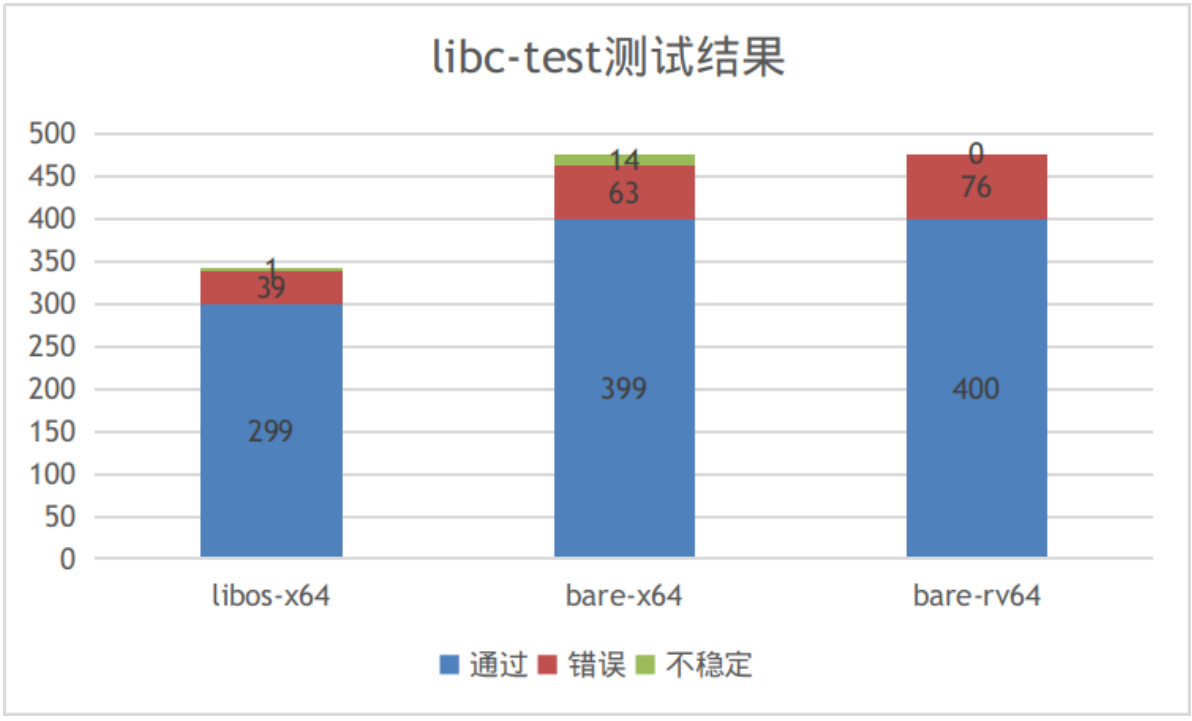

总体介绍 - zCore架构设计文档

zCore 架构设计文档

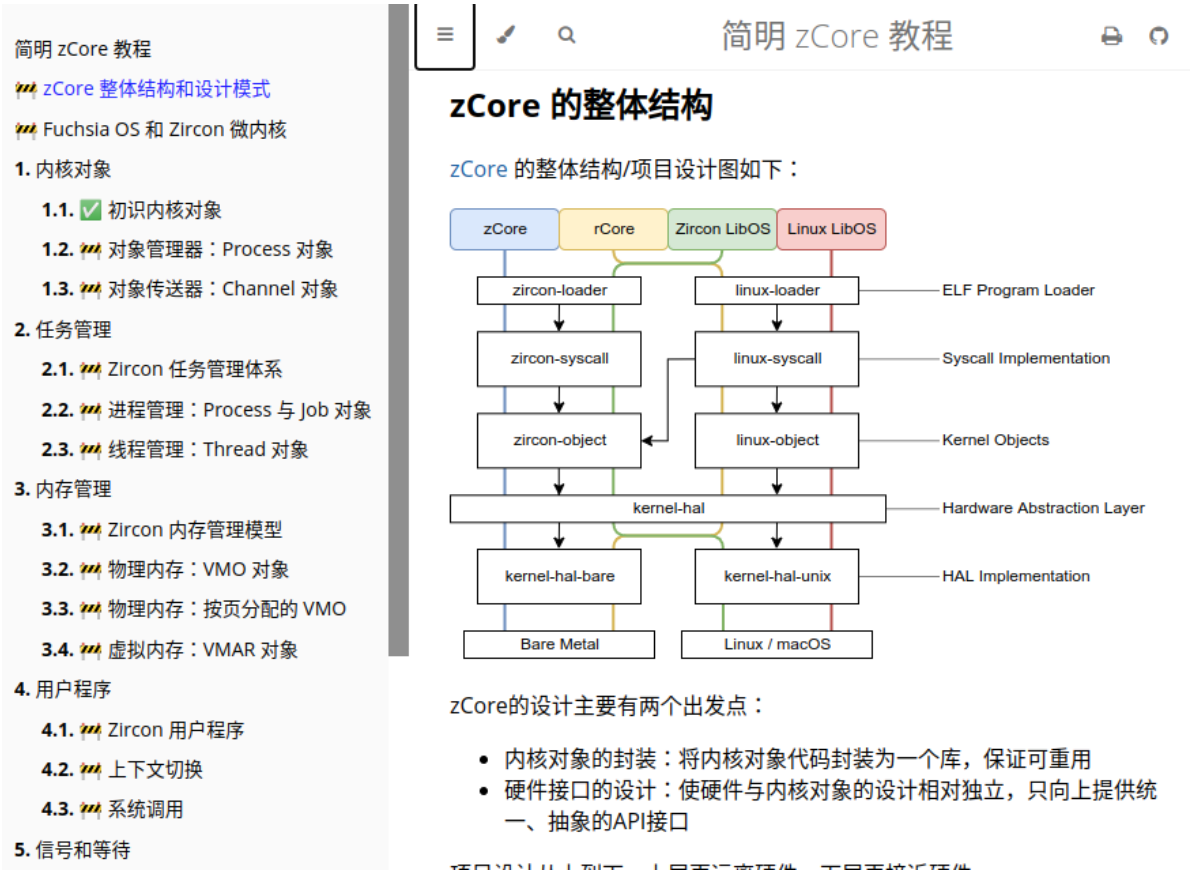

- zCore 接口文档

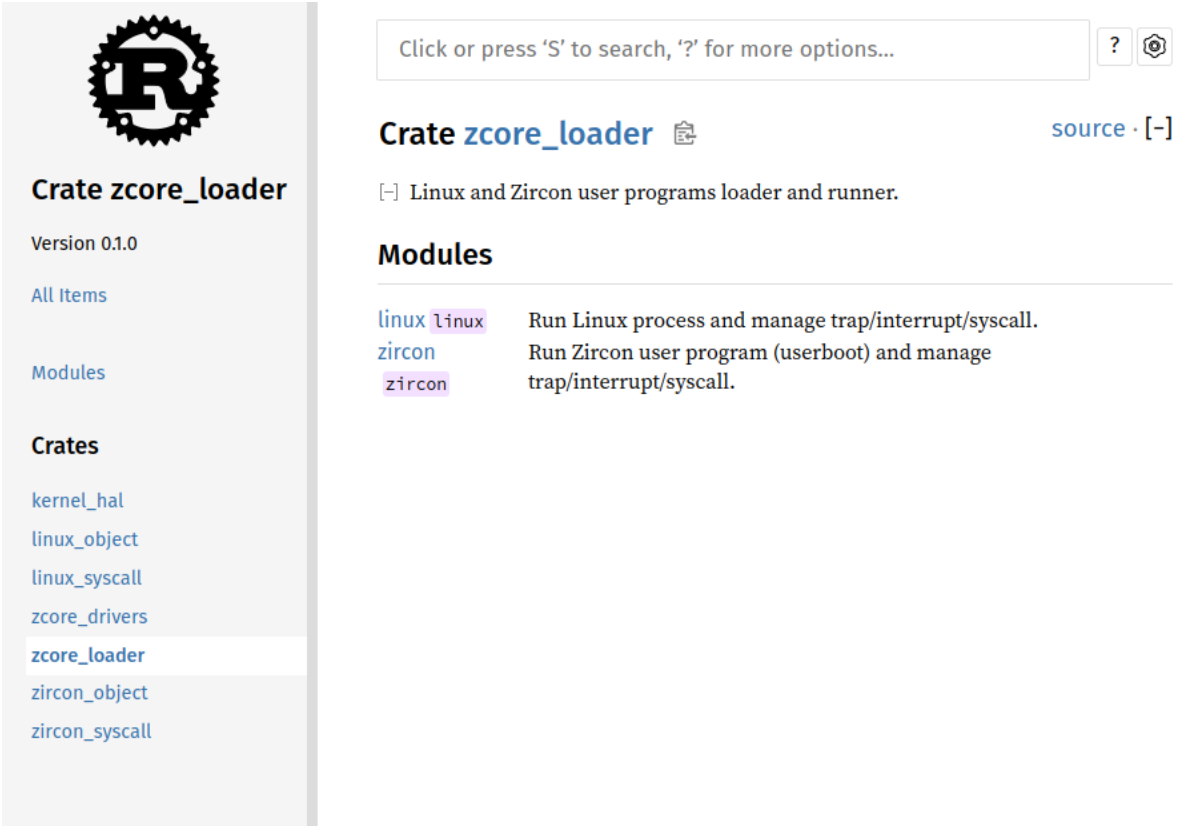

总体介绍 - 自动测试

文档与CI/CD集成测试

- `#![deny(warnings)]`：警告报错
- cargo fmt && clippy：检查代码格式和风格
- cargo build：保证所有平台编译通过
- cargo test：用户态单元测试，报告测试覆盖率
- core-test：内核态集成测试，维护通过测例列表
- （TODO）cargo bench：性能测试

上述测试全部通过才允许合入 master

总体介绍 - 模块化

rCore OS 生态 拆成小型 no_std crate，每个专注一件事：

- `trapframe-rs`：用户-内核态切换
- `rcore-console`：在 Framebuffer 上显示终端
- `naive-timer`：简单计时器
- `executor`：单线程 Future executor
- ……

提纲

- 总体介绍
- **各模块实现**
  - **初始化与第一个用户程序**
  - 两套 syscall 接口
  - 内核设计 -- 用户态HAL
  - 内核协程
  - 其他

初始化与第一个用户程序

- zCore: 调用 kernel-hal 接口，完成 内存 / 中断 等的初始化
- loader：加载第一个用户程序并运行
- [看代码]

提纲

- **各模块实现**
  - 初始化与第一个用户程序
  - **两套 syscall 接口**
  - 内核设计 -- 用户态HAL
  - 内核协程
  - 其他

两套 syscall 接口

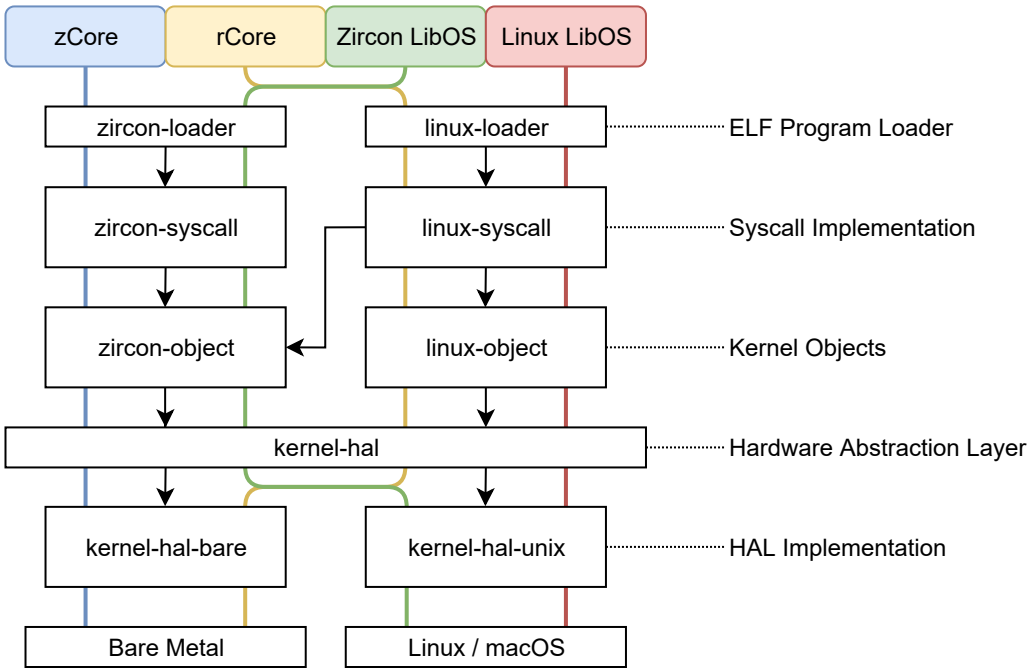

- [看代码：目录结构]

两套 syscall

- zircon 文档：https://fuchsia.dev/fuchsia-src/reference/syscalls
- zcore tutorial: https://rcore-os.github.io/zCore-Tutorial/
- syscall 入口：trapframe-rs / loader

提纲

- **各模块实现**
  - 初始化与第一个用户程序
  - 两套 syscall 接口
  - **内核设计 -- 用户态HAL**
  - 内核协程
  - 其他

内核设计 -- 用户态HAL

HAL 硬件抽象层的设计实现

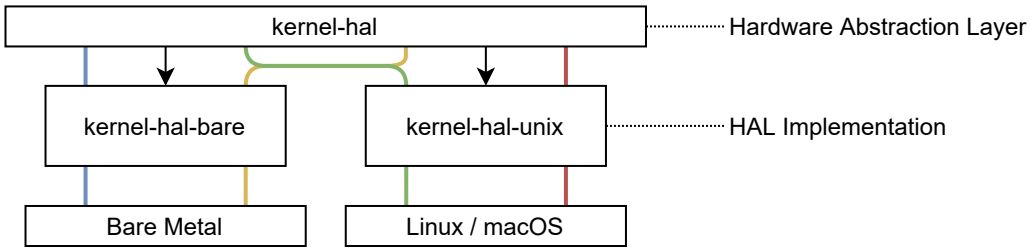

- Mode: bare-metal vs **libos**
- Arch: x86-64 vs riscv
- Platform: qemu vs d1

内核设计 -- 用户态HAL

需求：内核对象单元测试

- 测试对象：线程 `Thread`，内存映射 `VMO`，`VMAR`
- 但 `cargo test` 只能在开发环境用户态运行
- 思考：能否在用户态**模拟**页表和内核线程?

内核设计 -- 用户态HAL

方案：用户态模拟内核机制

- 内存映射：Unix `mmap` 系统调用
  - 用一个文件代表全部物理内存
  - 用 `mmap` 将文件的不同部分映射到用户地址空间
- log: stdin / stdout
- 磁盘：文件

进一步思考：

- 时钟中断?
- 测试驱动 / 测试页表内容?

内核设计 -- 用户态HAL

HAL API 举例

- 内核线程：`hal_thread_spawn`
- 物理内存：`hal_pmem_{read,write}`
- 虚拟内存：`hal_pt_{map,unmap}`
- 用户态：`hal_context_run`
- 定时器：`hal_timer_{set,tick}`
- 输入输出：`hal_serial_{read,write}`
- 设备管理：`hal_irq_{enable,handle}`
- [看代码]

内核设计 -- 用户态HAL

Challenge：用户-内核态切换 

- 控制流转移：系统调用 -> 函数调用
  - `int 80` / `syscall` -> `call`
  - `iret` / `sysret` -> `ret`
  - 需要修改用户程序代码段!
- 上下文恢复：寻找 "scratch" 寄存器
  - 用户程序如何找到内核入口点？内核栈?
  - 利用线程局部存储 TLS，线程指针 fsbase

提纲

- **各模块实现**
  - 初始化与第一个用户程序
  - 两套 syscall 接口
  - 内核设计 -- 用户态HAL
  - **内核协程**
  - 其他

内核设计 -- 异步调度

```rust
fn handler(mut stream: TcpStream) -> Result<()> {
    let mut buf = [0; 1024];
    let len = stream.read(&mut buf)?; // may block
    stream.write_all(&buf[0..len]))?; // may block
}
```

协程化

```rust
// fn handler(...) -> impl Future<Output = Result<()>>
async fn handler(mut stream: TcpStream) -> Result<()> {
    let mut buf = [0; 1024];
    let len = stream.read(&mut buf).await?;
    stream.write_all(&buf[0..len])).await?;
}
```

内核设计 -- 异步调度

异步调度：底层 --> 中层 --> 上层

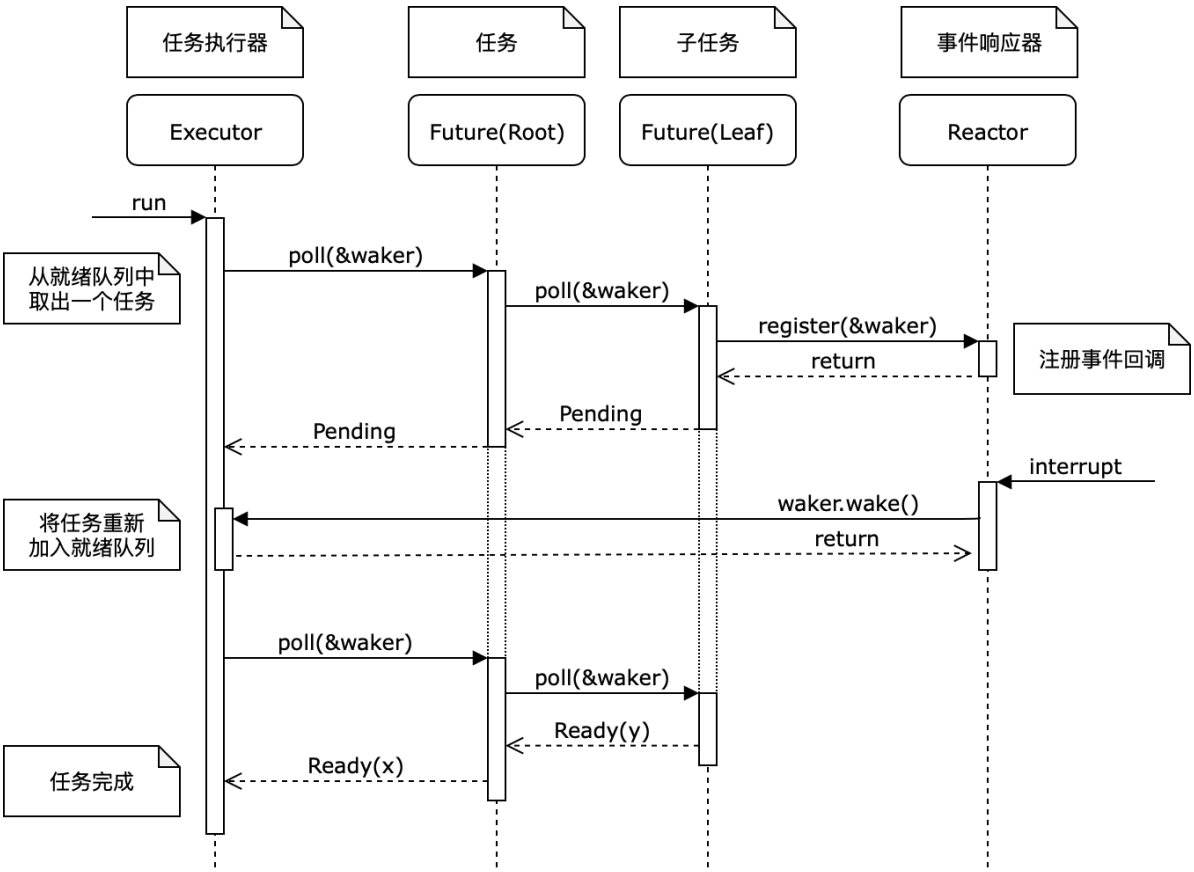

内核设计 -- 异步调度

底层：中断/异常事件处理：手动构造 Future

```rust
// 例：在内核对象上等待信号
struct WaitSignal {...}     // 定义一个状态机结构
impl Future for WaitSignal { // 实现 Future trait 的 poll 函数
    type Output = Signal;
    fn poll(self: Pin<&mut Self>, cx: &mut Context)
    -> Poll<Self::Output>
    {
        if self.signal().contains(signal) { // 若目标事件已发生，直接返回 Ready
            return Poll::Ready(signal);
        }

        let waker = cx.waker().clone(); // 尚未发生：注册回调函数，当事件发生时唤醒自己
        self.add_signal_callback(move || waker.wake());
        Poll::Pending
    }
}

fn wait_signal(&self, signal: Signal) -> impl Future<Output = Signal> {
    WaitSignal {...}   // 返回状态机对象
}
```

内核设计 -- 异步调度

中层：事件组合处理：用 async-await 组合 Future

```
async fn sys_object_wait_signal(...) -> Result {
    ...
    let signal = kobject.wait_signal(signal).await;
    ...
}
```

内核设计 -- 异步调度

中层：事件组合处理：用 async-await 组合 Future 用法：用 `select` 组合子实现 超时处理 和 异步取消

```
async fn sys_object_wait_signal(..., timeout) -> Result {
    ...
    let signal = select! {
        s = kobject.wait_signal(signal) => s,
        _ = delay_for(timeout) => return Err(Timeout),
        _ = cancel_token => return Err(Cancelled),
    };
    ...
}
```

内核设计 -- 异步调度

上层：异步内核函数：Executor 运行 Future

- libos：`tokio` / `async-std`，支持多线程，可以模拟多核
- bare：`rcore-os/executor`，简易单核
- [看代码：zCore/utils.rs]

提纲

- **各模块实现**
  - 初始化与第一个用户程序
  - 两套 syscall 接口
  - 内核设计 -- 用户态HAL
  - 内核协程
  - **其他**

其他

- zircon-user: 用户编译 zircon 用户程序
- linux-user ?
- 测试与运行

附录：Zircon 内核对象

Fuchsia 和 Zircon

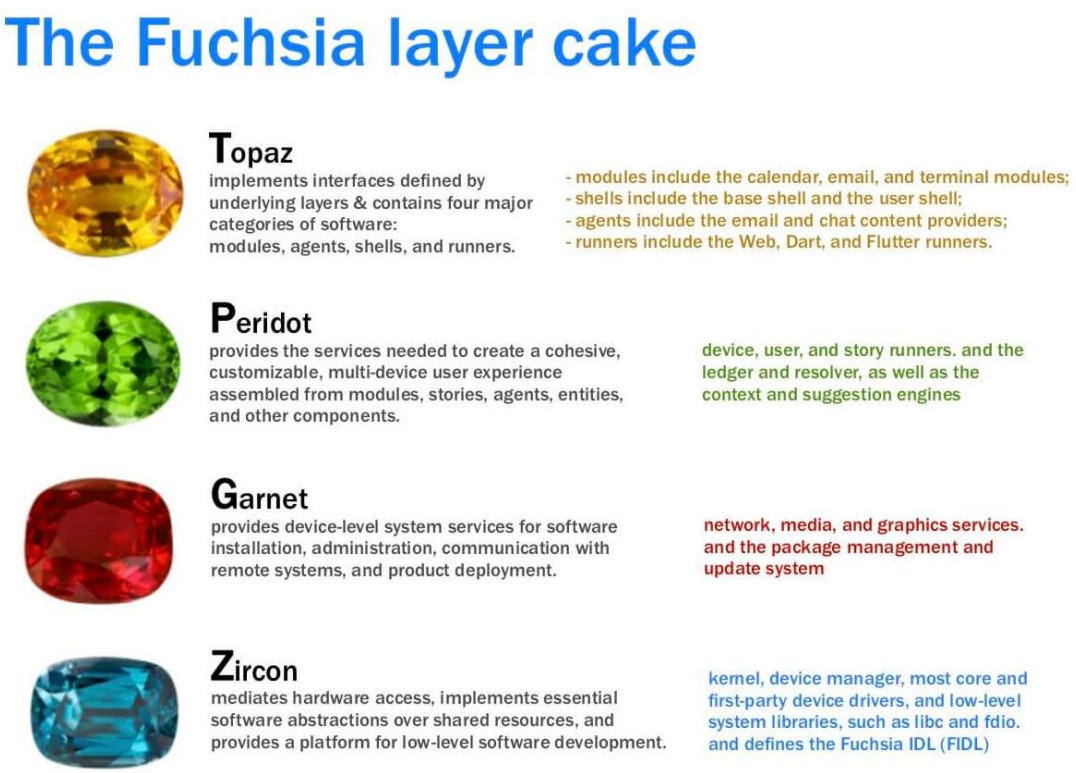

Zircon 内核对象 -- 特点

- 实用主义微内核
- 使用 C++ 实现，支持 x86_64 和 ARM64
- 面向对象：将功能划分到内核对象
- 默认隔离：使用 Capability 进行权限管理
- 安全考量：强制地址随机化，使用 vDSO 隔离系统调用

Zircon 内核对象 -- 用户执行环境

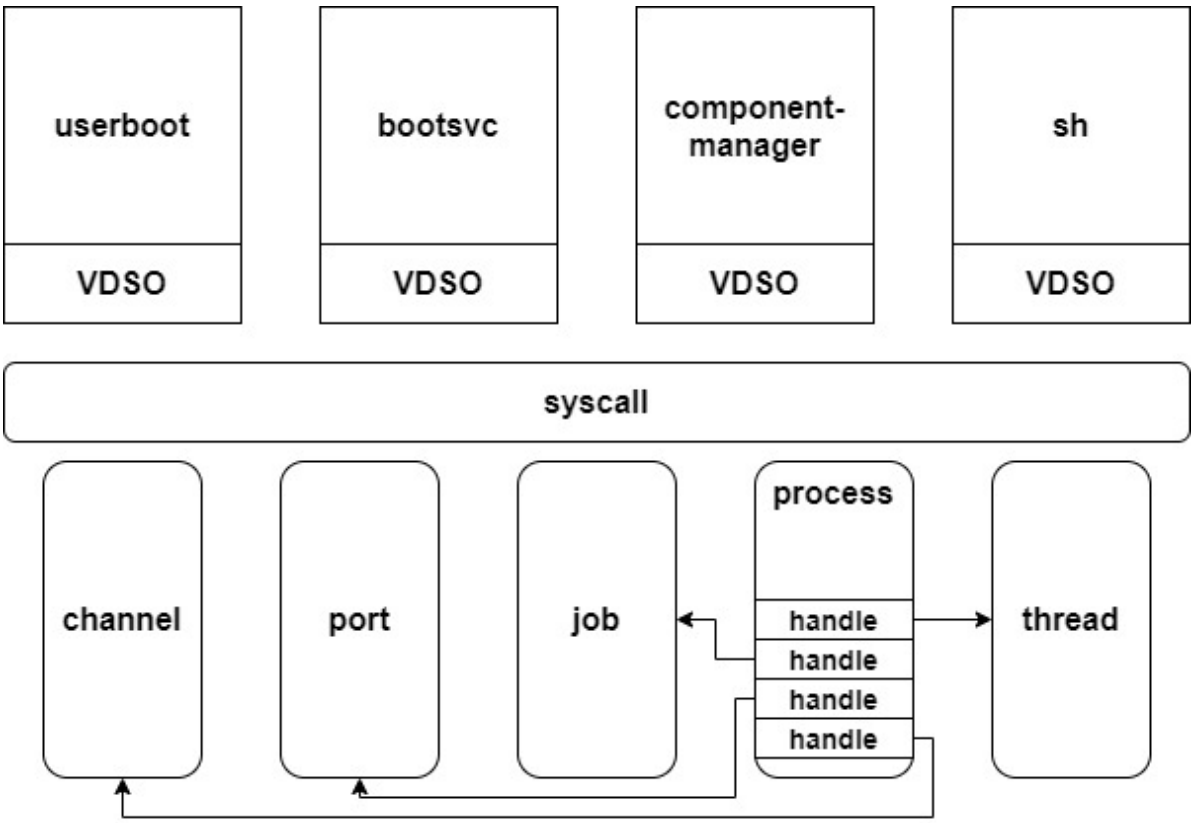

Zircon 内核对象 -- 主要组成

- Everything can be KernelObject
  - 任务：Job, Process, Thread, Exception
  - 内存：VMAR, VMO, Pager, Stream
  - IPC：Channel, FIFO, Socket
  - 信号：Event, Timer, Port, Futex
  - 驱动：Resource, Interrupt, PCI ...

Zircon 内核对象 -- Object

- Object：内核对象
- Rights：对象访问权限
- Handle = Object + Rights：对象句柄（类似 fd）

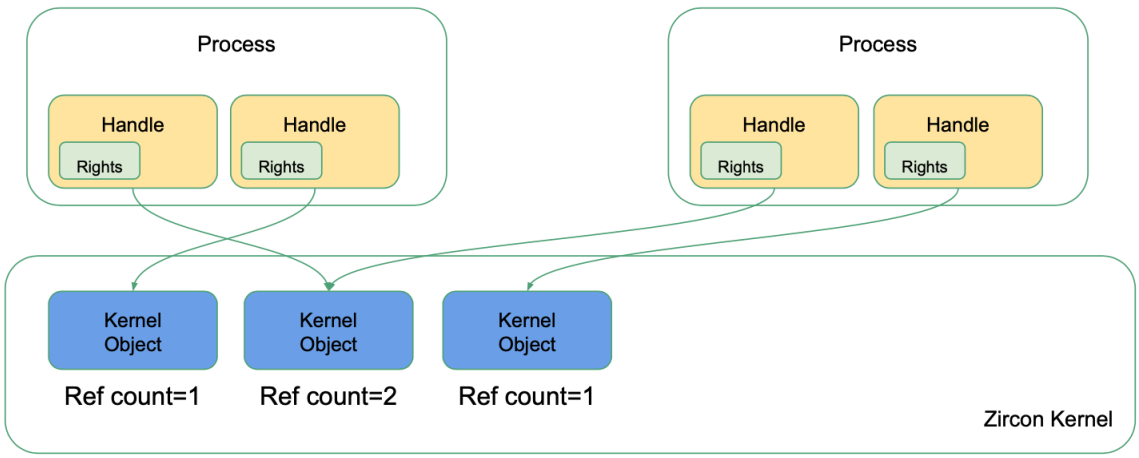

Zircon 内核对象 -- IPC

- Channel：进程间通信基础设施，可以传递数据和 handle
- FIFO：报文数据传输
- Socket：流数据传输

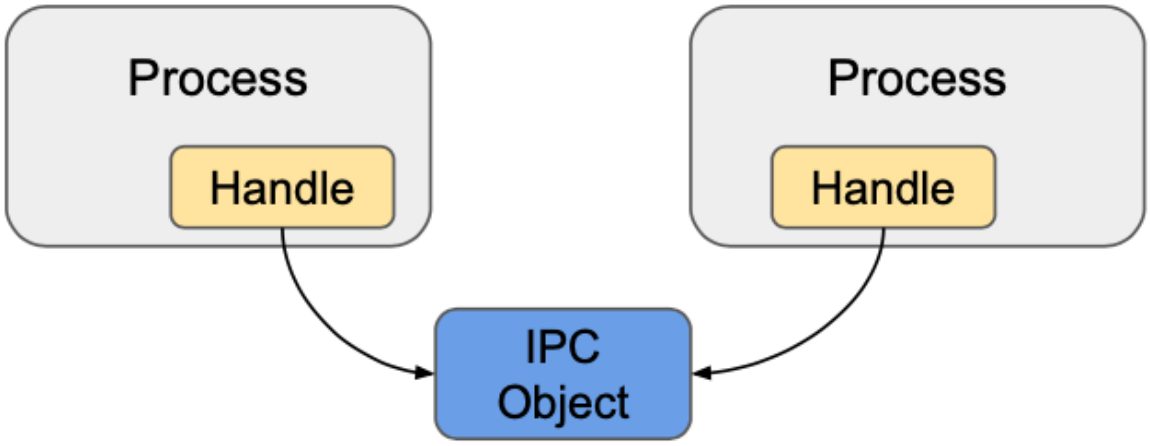

Zircon 内核对象 -- Tasks

- Job：作业，负责控制权限（类似容器）
- Process：进程，负责管理资源
- Thread：线程，负责调度执行

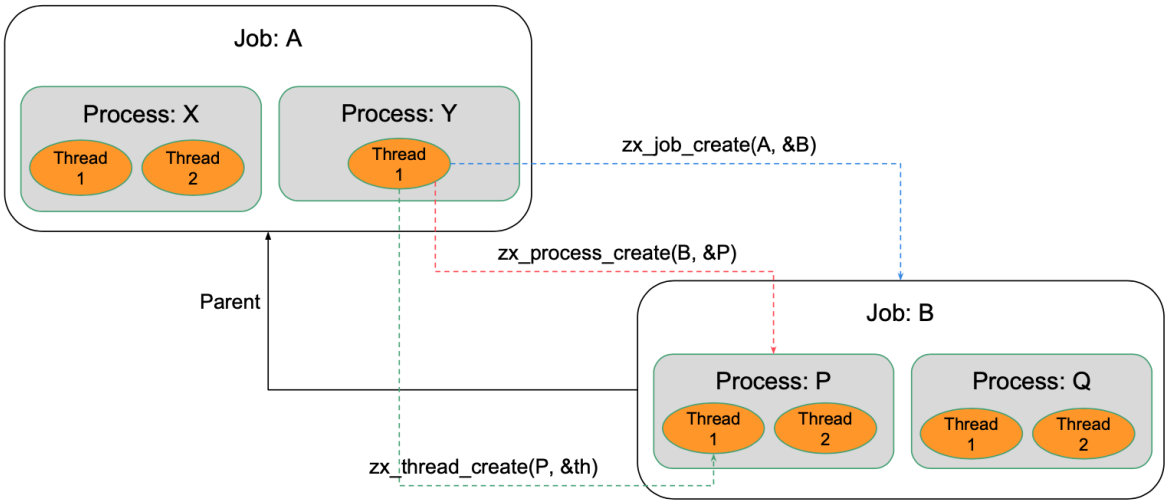

Zircon 内核对象 -- MAS

Memory and Address Apace

- VMO: Virtual Memory Object
  - Paged：分页物理内存，支持写时复制
  - Physical：连续物理内存 <!-- - 一段连续的虚拟内存，可以用于在进程之间、内核和用户空间之间共享内存
    - 在内核中被维护为类似线段树的数据结构，支持从一个VMO中创建新的VMO -->
- VMAR: Virtual Memory Address Region
  - 代表一个进程的虚拟地址空间

    - 树状结构
- Pager：用户态分页机制

Zircon 内核对象 -- Signaling /Waiting

每个 Object 有 32 个信号位，用户程序可以阻塞等待。

- Event (Pair)：事件源/对
- Timer：计时器
- Futex：用户态同步互斥机制
- Port：事件分发机制（类似 epoll）

附录：异步 syscall 简单测试

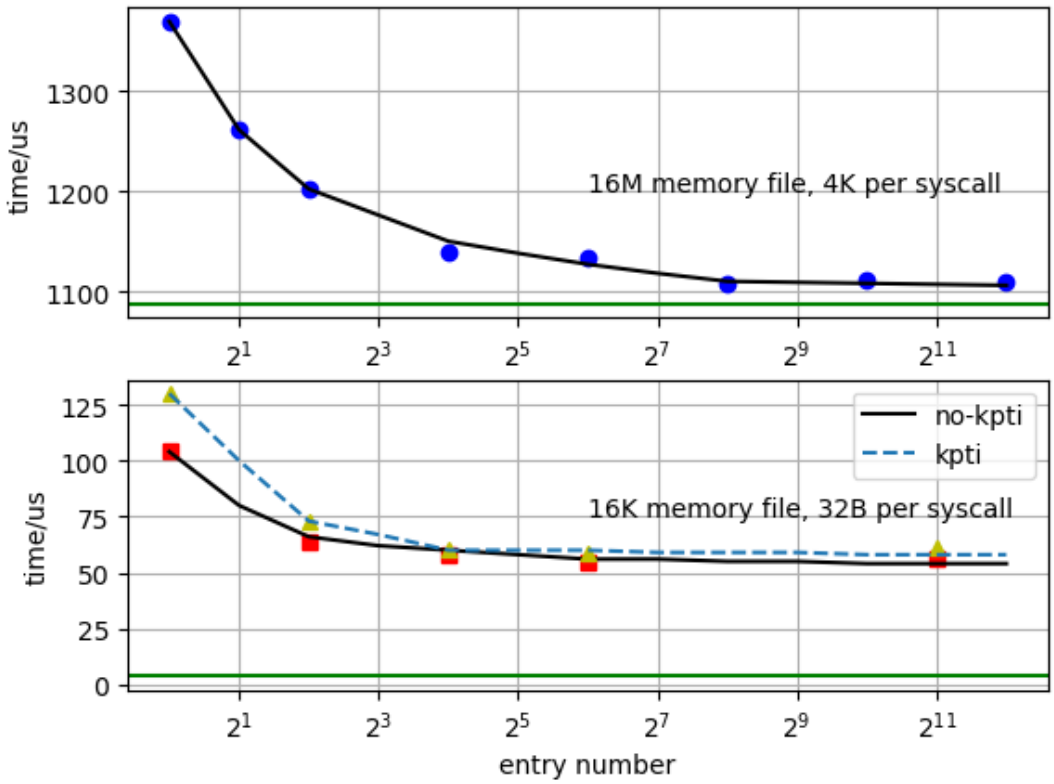

- allwinner nezha riscv

异步 syscall 的感知

- 如何感知异步 syscall ?

	CPU占用	Latency	Locality	备注
syscall	👍	👍	😟	
polling	😟	👍	👍	适合高速设备
free-polling	👍	😟	👍	
uintr	👍	👍	👍	需要硬件支持

zCore: free-polling + uintr

可抢占协程

- 异步执行 latency 的累加
  - 用户提交 => 内核感知, 内核提交 => 用户感知： uintr or polling
  - interrupt => 内核响应：优先级，可抢占协程
- 可退化的协程 = 可抢占的协程
  - 在中断 handler 里新建一个线程
  - 协程的线程间迁移

协程的调度

- 协程的类型
  - 内核协程：处理异步 syscall 的协程，polling 协程等
  - 用户协程：用户线程封装而成
- 核专用化
  - 内核核：内核协程，切换次数多，切换开销小
  - 用户核：用户协程，切换考校大，切换次数少
  - 如果更进一步：磁盘 IO 核，网络核
- 问题：load balance

协程切换开销

- thread switch => function return and call
- lmbench lat-ctx

```
Context switching - times in microseconds - smaller is better
-------------------------------------------------------------------------
Host                 OS  2p/0K 2p/16K 2p/64K 8p/16K 8p/64K 16p/16K 16p/64K
--------- ------------- ------ ------ ------ ------ ------ ------- -------
proc switch             0.3900 0.8800 0.8900 1.9200 2.2700 2.11000 2.25000
coroutine switch        0.0330 0.0390 0.0390 0.0600 0.0600 0.06800 0.06800
```

Zircon 内核对象 -- Signaling /Waiting

每个 Object 有 32 个信号位，用户程序可以阻塞等待。

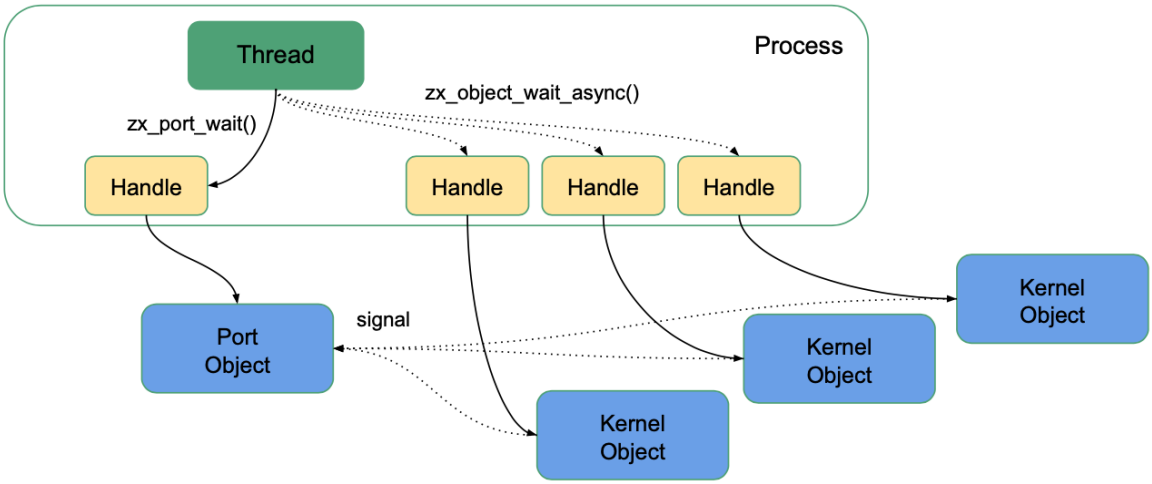

谢谢